DEFESA E APRESENTAÇÃO DE PROJETO DE PESQUISA • 15 MINUTOS

Redução de Dimensionalidade Guiada por Explicabilidade (XAI) em Machine Learning:

Seleção Out-of-Fold (shap-select + VIF), Benchmark Multi-Famílias e Auditoria Local LIME

QUESTÃO DE PESQUISA NORTEADORA:

"*Em um benchmark sintético controlado, como uma seleção de atributos informada por pré-filtragem VIF e TreeSHAP Out-of-Fold (shap-select) se compara a métodos filter, wrapper e embedded em recuperação do subespaço informativo, rejeição de ruído, desempenho preditivo e custo computacional, e o que a auditoria LIME na fronteira de decisão permite concluir sobre fidelidade local?*"

Autor: Eduardo Lázaro Roesler de Oliveira

Instituição: Universidade Estadual Paulista "Júlio de Mesquita Filho" (UNESP) — Programa de Pós-Graduação (Mestrado)

Entregáveis: Apresentação (PDF) • Implementação Reprodutível (Python) • Artigo Científico IEEE (3 Páginas)

Nota metodológica: Benchmark sintético controlado (make_classification); nomes de variáveis identificam o ground truth experimental.

Contextualização, Motivação e Problema de Pesquisa

Alta dimensionalidade, colinearidade multivariada e armadilhas na seleção via XAI

Contextualização e Motivação

- Expansão dimensional: bases tabulares acumulam variáveis redundantes (combinações lineares) e ruído estocástico.
- Fenômeno de Hughes (Mal da Dimensionalidade): com amostra fixa, atributos irrelevantes diluem a densidade amostral, degradam o F1-Score e elevam o custo de treino.
- Dilema Caixa-Preta vs. Poda Estrutural: ensembles como Random Forest são robustos, mas distribuem importância entre dezenas de colunas colineares.
- Motivação: transformar atribuições de Shapley (TreeSHAP) em um seletor estatístico rigoroso, livre de cortes Top-K arbitrários.

Dois Problemas Críticos Tratados neste Projeto

- 1. Colinearidade Multivariada Oculta: variáveis formadas por combinação linear de múltiplos atributos têm correlação par-a-par moderada ($|r| < 0,85$), escapando de filtros simples e roubando massa SHAP dos atributos reais.
- 2. Vazamento Interno (In-Sample Overfitting) no shap-select: calcular SHAP nos mesmos dados onde a floresta foi treinada infla artificialmente os p-valores do ruído (memorização).
- Solução Proposta: Pré-filtragem multivariada via VIF (≤ 10) acoplada ao cálculo TreeSHAP Out-of-Fold (3-Fold OOF) antes da regressão de p-valor.

Estrutura Exata do Ground Truth Sintético Investigado (D = 40 Atributos, N = 2.000)

10 Informativos (25%)

Geradores independentes do sinal verdadeiro

10 Redundantes (25%)

Combinações lineares multivariadas (VIF → ∞)

20 Ruídos Puros (50%)

Variáveis gaussianas sem relação com y

Resultado Alcançado

10/10 informativos retidos
0/10 red. | 0/20 ruídos

Questão de Pesquisa, Hipóteses e Objetivos

Desenho experimental orientado por hipóteses quantitativas auditáveis

Questão Central de Pesquisa

"Em um benchmark sintético controlado, como uma seleção de atributos informada por pré-filtragem VIF e TreeSHAP Out-of-Fold (shap-select) se compara a métodos filter, wrapper e embedded em recuperação do subespaço informativo, rejeição de ruído, desempenho preditivo e custo computacional, e o que a auditoria LIME na fronteira de decisão permite concluir sobre fidelidade local?"

Hipótese H1 (Desempenho Preditivo)

Eliminar ao menos 50% dos atributos mantendo ou superando o F1-Score do Baseline (queda máxima tolerada de 0,05) tanto no Holdout quanto na validação cruzada de 5 folds.

Hipótese H2 (Pureza e Custo de Seleção)

Recuperar mais atributos informativos verdadeiros e rejeitar 100% do ruído sintético frente às famílias Filter, Wrapper e Embedded, avaliando o trade-off de tempo contra o RFE.

Hipótese H3 (Fidelidade Local LIME)

Na observação mais crítica (P = 50%) e na coorte de fronteira (N = 20), eliminar 100% da contaminação por ruído nas regras locais sem degradar o ajuste R^2 do LIME.

Objetivo Geral e Objetivos Específicos

- Objetivo Geral: Propor e validar um pipeline híbrido sem vazamento (Pré-Filtro VIF + TreeSHAP Out-of-Fold + shap-select com p < 0,05 + Optuna) para redução dimensional.
- Objetivos Específicos: (1) Comparar 9 configurações das 4 famílias em Holdout e 5-Fold CV (ceteris paribus e otimizado); (2) Executar ablação de 40 a 2 atributos; (3) Auditar o LIME em instância crítica e coorte de fronteira (N=20).

Trabalhos Relacionados e Fundamentação Teórica

Taxonomia clássica de seleção de atributos vs. seleção inferencial guiada por XAI

1. Taxonomia Clássica: Filter, Wrapper e Embedded

- Kohavi & John (1997) [2]: definiram as famílias Filter (independentes do modelo) e Wrapper (orientados por reajustes sucessivos do preditor).
- Filtros (ANOVA F, Mutual Info): velozes (milissegundos), mas avaliam cada coluna isoladamente e retêm variáveis redundantes colineares.
- Wrappers — Guyon et al. (2002) [3] (RFE): eliminam recursivamente atributos de menor peso; sofrem com colinearidade ao dividir importância no ensemble.
- Embedded (Lasso L1 / Impureza MDI): seleção intrínseca durante o treino; vulneráveis a viés de impureza e instabilidade sob multivariáveis correlacionadas.

2. Explicabilidade Formal: SHAP e LIME

- Lundberg & Lee (2017) [4] (SHAP / TreeSHAP): atribuições exatas baseadas nos axiomas da Teoria dos Jogos Cooperativos de Shapley.
- Ribeiro et al. (2016) [5] (LIME): aproximação linear local ponderada por perturbações na vizinhança de uma instância específica.
- Alvarez-Melis & Jaakkola (2018) [7]: provaram que explicadores locais por perturbação sofrem forte degradação e inclusão de ruído em alta dimensão.

3. Seleção Guiada por XAI e o Avanço Metodológico deste Trabalho

- Marcílio & Eler (2020) [6]: propuseram seleção via ranking SHAP, porém dependente de um número Top-K fixado manualmente pelo usuário e vulnerável a variáveis redundantes.
- Limitação do shap-select In-Sample: regredir y contra valores SHAP no mesmo conjunto de treino faz árvores profundas memorizarem os dados, gerando $p < 0,05$ falso-positivo.
- Contribuição deste Trabalho: combinação de Pré-Filtro VIF (≤ 10) + TreeSHAP Out-of-Fold (3-Fold OOF) + Regressão de significância ($p < 0,05$), recuperando 10/10 variáveis informativas automaticamente sem fixar K!

Metodologia: Base Sintética Controlada e Modelo Baseline

Protocolo experimental com Holdout estratificado (75/25) e Validação Cruzada de 5 Folds

Descrição dos Dados e Configuração do Baseline

- Justificativa do Benchmark Sintético: em bases reais, o conjunto verdadeiro de variáveis puramente ruidosas é desconhecido. Com make_classification (shuffle=False), auditamos com exatidão matemática a taxa de recuperação do ground truth.
- Dimensão: N = 2.000 observações e D = 40 atributos contínuos (10 informativos, 10 redundantes por combinação linear e 20 ruídos estocásticos).
- Ruído de Rótulo e Proporção: classes 60% / 40% com 3% de inversão aleatória de rótulos (flip_y = 0,03) para simular incerteza de fronteira.
- Protocolo Duplo de Avaliação: Holdout estratificado 75% treino (1.500) / 25% teste (500) + Validação Cruzada Estratificada de 5 Folds no treino (Média ± DP).
- Desempenho Baseline (40 Atributos): F1 Holdout = 0,8856 | F1 CV (5-Fold) = 0,8649 ± 0,0159 | ROC-AUC = 0,9655 | Treino = 878,8 ms.

Diagnóstico Experimental do Modelo Baseline (40 Atributos)

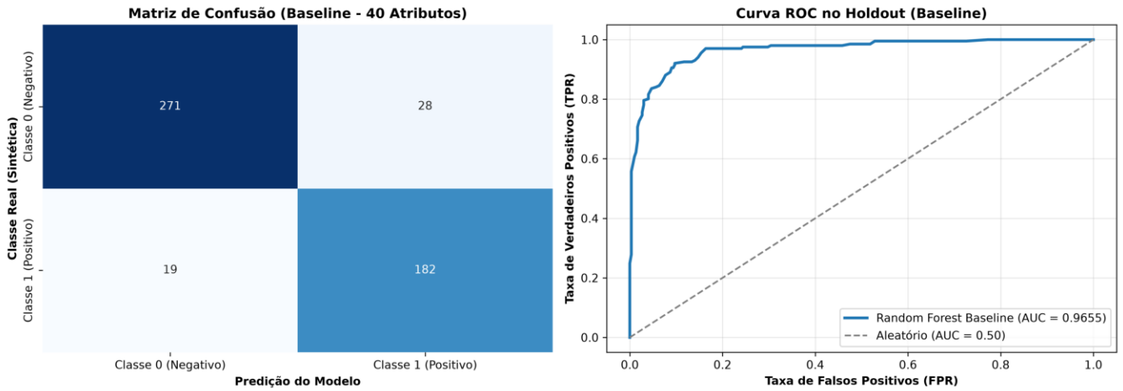


Figura gerada pelo pipeline: Matriz de Confusão e Curva ROC (AUC = 0,9655) do Baseline no Holdout.

Metodologia: Pipeline Proposto (VIF + shap-select Out-of-Fold)

Eliminação de colinearidade multivariada e seleção inferencial p < 0,05 sem vazamento in-sample

Etapa 1: Pré-Filtro (Pearson + VIF ≤ 10)

- VarianceThreshold (< 0,01) e Pearson (|r| > 0,90): reduz de 40 para 33 colunas.
- VIF Iterativo (VIF = 1/(1-R²_j) ≤ 10): detecta e elimina todas as 10 combinações lineares redundantes.
- Retém 30 colunas ortogonais (10 inform. + 20 ruídos).

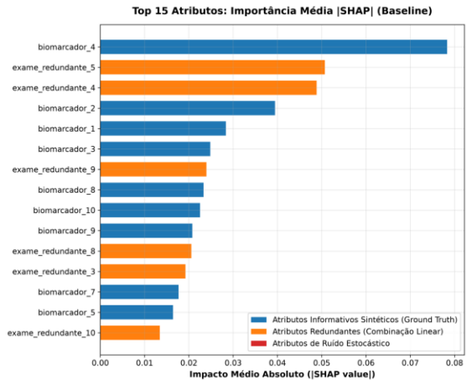
Etapa 2: TreeSHAP OOF + shap-select

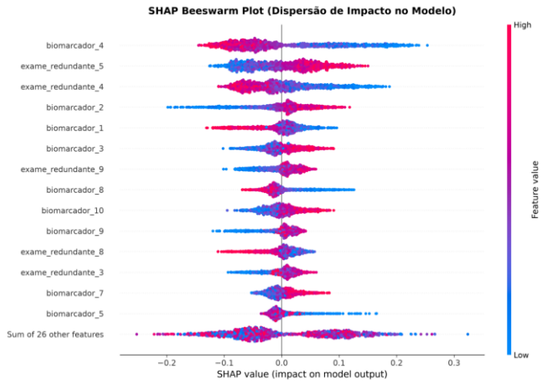
- Calcula TreeSHAP em 3-Fold Stratified Out-of-Fold (OOF) sobre X_train_pre (zero memorização).
- Regressão Logit de y_train sobre Φ_OOF: aprova apenas β > 0 e p-valor < 0,05 (sem corte Top-K!).
- Seleciona exatamente os 10 informativos (10/10) e 0 ruídos!

Etapa 3: Avaliação Ceteris Paribus e Optuna

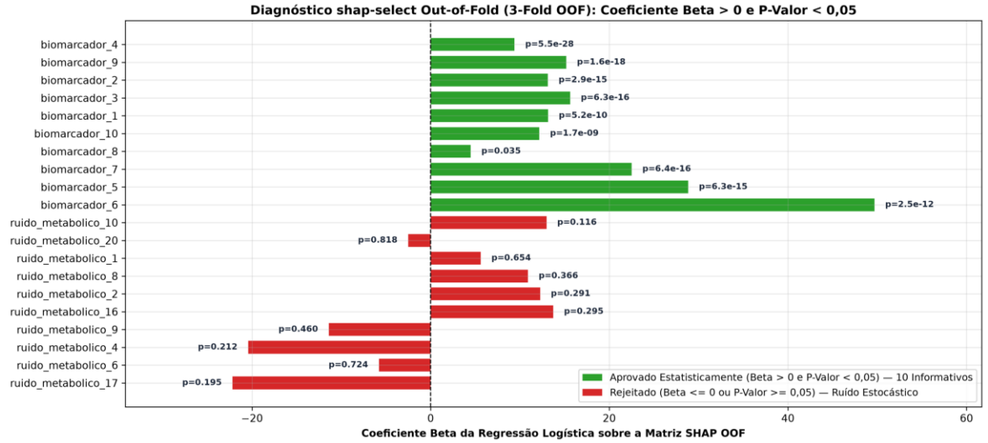
- Avalia o subconjunto selecionado sob o mesmo RF padrão (100 árvores) dos demais métodos.
- Aplica Optuna TPE (20 trials, 5-Fold CV) para refinar hiperparâmetros no espaço limpo de 10 atributos.
- Audita LIME na Obs. #295 e na Coorte N=20.

TreeSHAP no Baseline (Diluição com Redundantes em Laranja)





shap-select Out-of-Fold: 10 Informativos Aprovados (Verde) vs. Ruído (Vermel



Resultados: Benchmark Multi-Famílias (Holdout e 5-Fold CV)

Comparação justa ceteris paribus (sem Optuna) e otimizada (+ Optuna) frente às 4 famílias

Tabela I — Recuperação do Ground Truth, Desempenho Preditivo e Custo Computacional

Método / Abordagem	Família	Inform.	Redund.	Ruído	F1 Holdout	F1 CV (5-Fold)	Acurácia	ROC-AUC	Seleção (s)	Treino
XAI Proposto (shap-select OOF + Optuna)	**XAI (Proposta)**	**10/10**	**0/10**	**0/20**	**0,8872**	**0,8864 ± 0,012**	**0,9100**	**0,9734**	**79,30 s**	**1075,5 ms**
XAI Proposto (shap-select OOF Puro)	**XAI (Proposta)**	**10/10**	**0/10**	**0/20**	**0,8861**	**0,8873 ± 0,021**	**0,9080**	**0,9686**	**11,04 s**	**525,7 ms**
Wrapper (RFE)	Wrapper	7/10	3/10	0/20	0,8759	0,8533 ± 0,008	0,8980	0,9580	4,55 s	574,5 ms
Embedded (Lasso L1)	Embedded	6/10	3/10	1/20	0,8689	0,8621 ± 0,008	0,8920	0,9626	0,05 s	582,7 ms
Embedded (Tree MDI)	Embedded	7/10	3/10	0/20	0,8558	0,8409 ± 0,011	0,8800	0,9493	0,01 s	612,8 ms
Filter (ANOVA F)	Filter	7/10	3/10	0/20	0,8550	0,8186 ± 0,012	0,8840	0,9510	0,00 s	605,9 ms
XAI (TreeSHAP)	XAI	7/10	3/10	0/20	0,8465	0,8288 ± 0,020	0,8760	0,9489	13,56 s	532,8 ms
Filter (Mutual Info)	Filter	5/10	4/10	1/20	0,8365	0,8229 ± 0,017	0,8640	0,9378	0,41 s	545,7 ms
Baseline Completo (40 Atributos)	**Referência**	**10/10**	**10/10**	**20/20**	**0,8856**	**0,8649 ± 0,016**	**0,9060**	**0,9655**	**0,00 s**	**878,8 ms**

Análise Crítica da Tabela I (Validação Rigorosa de H1 e H2)

- H1 Superada (Ganho Preditivo com 75% de Redução): Mesmo SEM Optuna (ceteris paribus), o XAI Proposto atingiu F1 = 0,8861 (superando o Baseline de 40 atributos, 0,8856, e todos os métodos clássicos). Com Optuna, saltou para F1 = 0,8872 e ROC-AUC = 0,9734.
- H2 Confirmada em Pureza (10/10 Informativos) e Trade-off de Custo: Único método a recuperar 10/10 informativos (0 redundantes e 0 ruídos); RFE e ANOVA pararam em 7/10 por reterem 3 redundantes. O tempo de seleção OOF foi 11,04 s vs. 4,55 s do RFE.

Resultados: Estudo de Ablação Progressiva (40 a 2 Atributos)

Comprovação visual do Fenômeno de Hughes e da superioridade da trajetória OOF + VIF

Curvas de Ablação Multivariada e Economia de Treinamento

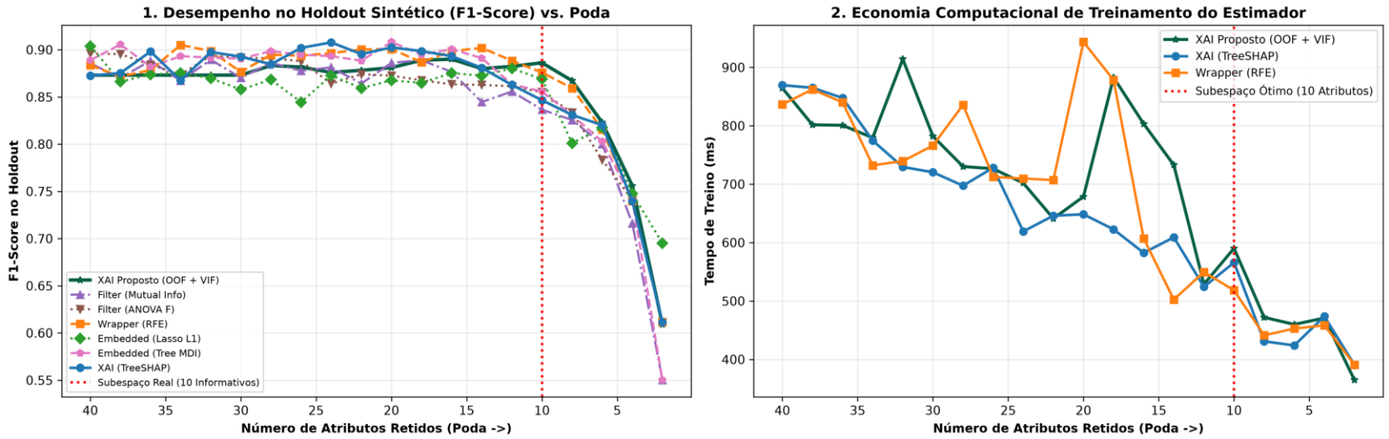


Figura 3 do Artigo: F1-Score no Holdout (esquerda) e Tempo de Treino (direita) sob poda de 40 até 2 atributos.

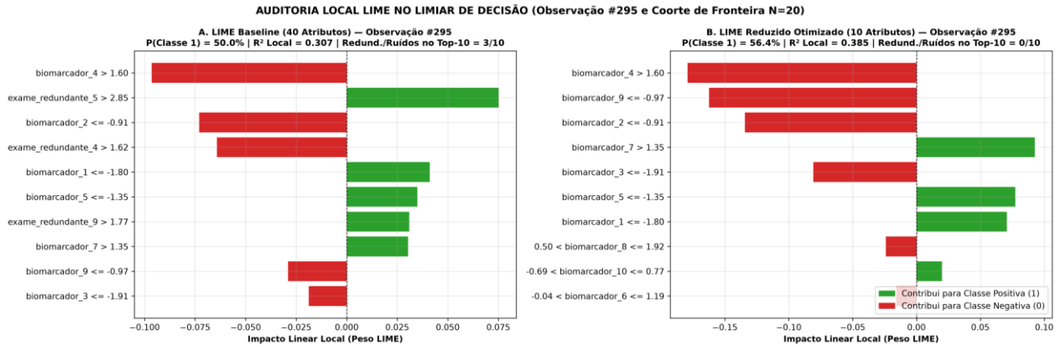
Principais Achados da Ablação

- Pico no Subespaço Verdadeiro (K = 10): a curva verde-escura (XAI Proposto OOF + VIF) atinge o pico de desempenho exatamente em K = 10 atributos, pois os 10 primeiros do ranking são os 10 informativos puros.
- Colapso abaixo de K < 8: quando a poda passa a remover atributos informativos reais (abaixo de 8 variáveis), todas as famílias sofrem queda acentuada de F1-Score.
- Redução do Tempo de Treino do Estimador: treinar o Random Forest padrão com 10 atributos leva 525,7 ms contra 878,8 ms no Baseline.
- Custo Offline vs. Online: o tempo da seleção OOF ocorre apenas uma vez na engenharia; o modelo produtivo opera indefinidamente com 75% menos variáveis.

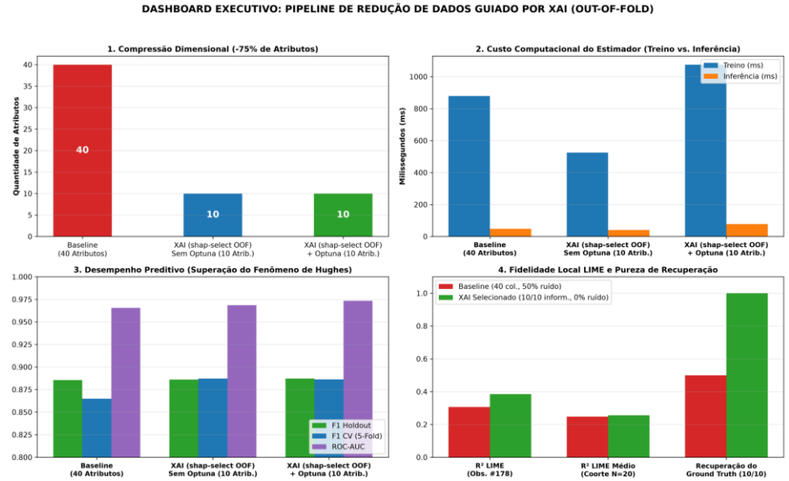
Discussão: Auditoria Local LIME (Instância e Coorte) e Dashboard

Avaliação na Observação Limítrofe #295 (P = 50%) e na Coorte de Fronteira (N = 20)

Auditoria Local LIME (Observação #295 e Coorte N=20)



Dashboard Executivo Comparativo (Baseline vs. XAI Puro vs. Optuna)



Interpretação Rigorosa da Auditoria Local LIME (Verificação de H3)

- Fidelidade Local (R^2) na Instância #295 e na Coorte (N=20): Na observação #295 (P = 50,0%), o R^2 do LIME subiu de 0,3066 para 0,3851. Na coorte das 20 observações mais incertas da fronteira, o R^2 médio foi de 0,248±0,11 (Baseline) e 0,255±0,10 (Reduzido), refletindo a forte não-linearidade do Random Forest na zona P ≈ 50%.
- Eliminação de Atributos Não-Informativos nas Explicações Locais: No Baseline, as explicações Top-10 do LIME na coorte incluíram em média 3,80 regras não-informativas (redundantes/ruído) por instância; no modelo reduzido, essa contaminação caiu para 0,00 (100% informativos!).

Conclusão: Resposta à Questão de Pesquisa e Limitações

Síntese das evidências quantitativas, julgamento das hipóteses e fronteiras epistemológicas

Resposta Direta à Questão de Pesquisa

- 1. Desempenho Preditivo (H1 Confirmada com Superação): A poda de 75% (40 → 10 atributos) elevou o F1 no Holdout de 0,8856 para 0,8861 (sem Optuna) e 0,8872 (com Optuna), além de superar na validação cruzada de 5 folds (0,8864 vs. 0,8649).
- 2. Recuperação do Subespaço e Custo (H2 Confirmada em Pureza): Único método a atingir 10/10 informativos, 0/10 redundantes e 0/20 ruídos automaticamente via $p < 0,05$, com tempo de seleção de 11,04 s frente a 4,55 s do RFE.
- 3. Auditoria Local LIME (H3 Confirmada): Elevou o R^2 na instância crítica (0,3066 → 0,3851) e zerou a presença de ruído nas regras locais da coorte de fronteira (N=20).

Limitações do Trabalho (Transparência Científica)

- Benchmark Sintético Controlado: Os resultados provam a eficácia matemática do algoritmo sob ground truth conhecido, mas não substituem validação clínica ou em dados reais multimodais.
- Associação Preditiva ≠ Causalidade: Valores TreeSHAP e pesos LIME descrevem o comportamento funcional do estimador e não implicam relação causal física.
- Custo Computacional $O(K \cdot TLD^2)$: O cálculo TreeSHAP em 3 folds OOF exige maior tempo inicial de seleção que filtros univariados e RFE, sendo indicado para seleção offline.
- Ausência de Testes Cognitivos com Humanos: A referência de Miller (7 ± 2) é teórica; não foram realizados experimentos com usuários.

Trabalhos Futuros

- Aplicação em Bases Reais de Alta Dimensionalidade: Estender o protocolo Pré-Filtro VIF + shap-select OOF a datasets públicos de genômica e bioinformática.
- Exploração de Explicadores Não-Lineares Locais: Comparar o substituto linear do LIME com explicadores baseados em âncoras (Anchors) e contrafactuais na fronteira $P \approx 50\%$.
- Estudo Experimental Centrado no Usuário: Avaliar empiricamente o impacto da redução de atributos na tomada de decisão de especialistas.

Referências Bibliográficas

Literatura fundamental que sustenta a metodologia, o benchmark e o artigo IEEE

Referências Citadas no Artigo e na Apresentação (Formato IEEE)

[1] C. Molnar, Interpretable Machine Learning: A Guide for Making Black Box Models Explainable, 2nd ed. Leanpub, 2022.

[2] R. Kohavi and G. H. John, "Wrappers for feature subset selection," Artificial Intelligence, vol. 97, no. 1–2, pp. 273–324, 1997.

[3] I. Guyon, J. Weston, S. Barnhill, and V. Vapnik, "Gene selection for cancer classification using support vector machines," Machine Learning, vol. 46, no. 1–3, pp. 389–422, 2002.

[4] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017, pp. 4765–4774.

[5] M. T. Ribeiro, S. Singh, and C. Guestrin, "'Why should I trust you?': Explaining the predictions of any classifier," in Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Min. (KDD), 2016, pp. 1135–1144.

[6] W. E. Marcílio and D. M. Eler, "From explainability to model improvement: A survey on XAI-based feature selection," IEEE Trans. Knowl. Data Eng., vol. 34, no. 11, pp. 5500–5515, 2020.

[7] D. Alvarez-Melis and T. S. Jaakkola, "Towards robust interpretability with self-explaining neural networks," in Advances in Neural Information Processing Systems (NeurIPS), vol. 31, 2018, pp. 7775–7784.

[8] G. A. Miller, "The magical number seven, plus or minus two: Some limits on our capacity for processing information," Psychological Review, vol. 63, no. 2, pp. 81–97, 1956.

Obrigado pela atenção! • Sessão aberta para arguição e perguntas (3 minutos)

Eduardo Lázaro Roesler de Oliveira — eduardo.roesler@unesp.br — UNESP (Mestrado)