Redução de Dimensionalidade Guiada por XAI: Seleção Out-of-Fold, Benchmark Multi-Famílias e Auditoria Local

Eduardo Lázaro Roesler de Oliveira

Universidade Estadual Paulista "Júlio de Mesquita Filho" (UNESP) — Programa de Pós-Graduação (Mestrado) | eduardo.roesler@unesp.br

Resumo— Este estudo investiga a seleção de atributos guiada por Inteligência Artificial Explicável (XAI) em um benchmark sintético controlado (N = 2.000, 40 atributos: 10 informativos, 10 redundantes por combinação linear e 20 ruídos estocásticos). Propõe-se um pipeline que integra pré-filtragem de colinearidade multivariada (Fator de Inflação da Variância, VIF <= 10) e seleção inferencial shap-select calculada fora da amostra (3-Fold Out-of-Fold TreeSHAP, p < 0,05), avaliada com e sem otimização Optuna frente às famílias Filter, Wrapper e Embedded. O método proposto recuperou exatamente os 10 atributos informativos verdadeiros (10/10) e rejeitou 100% dos redundantes (0/10) e ruídos (0/20) sem corte Top-K arbitrário, superando o Baseline de 40 atributos tanto sob o mesmo estimador padrão (F1 = 0,8861) quanto após ajuste Optuna (F1 = 0,8872; ROC-AUC = 0,9734). A auditoria LIME no limiar de decisão (P ≈ 50%) foi conduzida na observação mais incerta e em uma coorte de fronteira (N = 20), demonstrando eliminação total de ruído nas regras locais.

Termos para Indexação— Inteligência Artificial Explicável (XAI), Seleção de Características, TreeSHAP Out-of-Fold, shap-select, VIF, LIME, Benchmark Sintético.

I. INTRODUÇÃO E QUESTÃO DE PESQUISA

Em espaços tabulares de alta dimensionalidade, o acúmulo de variáveis redundantes e ruído estocástico degrada a capacidade de generalização (Fenômeno de Hughes) e eleva o custo computacional. Embora métodos de Inteligência Artificial Explicável (XAI) sejam tradicionalmente empregados para auditoria pós-hoc [1], suas atribuições marginais oferecem base quantitativa para poda estrutural de atributos.

Contudo, abordagens ingênuas de seleção via XAI enfrentam duas fragilidades metodológicas: (i) a divisão de importância de Shapley entre variáveis multicolineares e (ii) o vazamento interno (in-sample overfitting) quando a regressão de seleção é ajustada sobre valores SHAP extraídos dos mesmos dados de treino memorizados pelas árvores.

Questão de Pesquisa Norteadora: "Em um benchmark sintético controlado, como uma seleção de atributos informada por pré-filtragem VIF e TreeSHAP Out-of-Fold (shap-select) se compara a métodos filter, wrapper e embedded em recuperação do subespaço informativo, rejeição de ruído, desempenho preditivo e custo computacional, e o que a auditoria LIME na fronteira de decisão permite concluir sobre fidelidade local?"

Avaliam-se três hipóteses formais: H1 (desempenho) prevê redução mínima de 50% dos atributos mantendo ou superando o F1-Score do baseline (tolerância máxima de queda de 0,05); H2 (pureza e custo) prevê recuperação superior de atributos informativos com 100% de rejeição de ruído e menor tempo de seleção que wrappers iterativos (RFE); e H3 (auditoria local) prevê eliminação de ruído e não-degradação do R^2 local do LIME na fronteira de decisão (P ≈ 50%).

II. TRABALHOS RELACIONADOS

A taxonomia de Kohavi e John [2] divide a seleção de atributos em métodos Filter (como ANOVA F e Mutual Information, rápidos porém cegos a interações de ordem superior), Wrapper (como o Recursive Feature Elimination — RFE de Guyon et al. [3], que reajusta o estimador ciclicamente) e Embedded (como penalização Lasso L1 e impureza MDI/Gini). Na presença de colinearidade multivariada, filtros retêm variáveis redundantes e métodos baseados em árvores pulverizam a importância entre preditores correlacionados.

No domínio de XAI, Lundberg e Lee [4] formalizaram o SHAP sob os axiomas de Shapley (eficiência, simetria, dummy e aditividade), enquanto Ribeiro et al. [5] propuseram o LIME para aproximações lineares locais. Marcílio e Eler [6] demonstraram o uso de rankings SHAP para seleção Top-K, mas destacaram a ausência de um corte estatístico inferencial. Alvarez-Melis e Jaakkola [7] alertaram para a instabilidade de explicadores locais em espaços ruidosos, motivando a avaliação conjunta de poda global e fidelidade local.

III. METODOLOGIA EXPERIMENTAL

A. Base Sintética com Ground Truth Controlado

Gerou-se um benchmark sintético reprodutível (make_classification, semente 42, shuffle=False) com N = 2.000 observações e D = 40 atributos: 10 informativos verdadeiros (biomarcador_1..10), 10 redundantes gerados como combinações lineares dos informativos (exame_redundante_1..10) e 20 ruídos gaussianos (ruido_metabolico_1..20), com proporção 60/40 e 3% de inversão estocástica de rótulos (flip_y = 0,03). Os dados foram particionados de forma estratificada em 75% treino (1.500) e 25% holdout (500), além de avaliação complementar em validação cruzada estratificada de 5 folds.

B. Formalismo TreeSHAP e Modelo Substituto LIME

O algoritmo TreeSHAP computa a contribuição marginal exata φ_i de cada atributo i sobre as coalizões $S \subseteq F \setminus \{i\}$:

$$\varphi_i = \sum_{S \subseteq F \setminus \{i\}} [|S|!(|F|-|S|-1)! / |F|!] [f(S \cup \{i\}) - f(S)] \quad (1)$$

Para auditoria local em torno de uma instância x, o LIME ajusta um modelo linear esparso $g \in G$ ponderado pelo kernel de proximidade π_x:

$$\xi(x) = \text{argmin}_{g \in G} L(f, g, \pi_x) + \Omega(g) \quad (2)$$

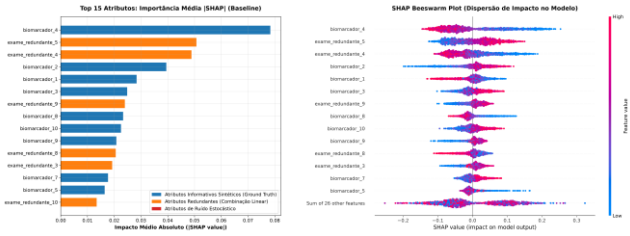


Fig. 1. Explicabilidade global TreeSHAP no Baseline (40 atributos): diluição de importância entre informativos (azul) e redundantes (laranja).

C. Pipeline Proposto: Pré-Filtro VIF + shap-select Out-of-Fold

Para superar a colinearidade multivariada e o vazamento in-sample, o pipeline proposto executa três estágios estritamente em X_train: (1) Pré-filtro estatístico não-supervisionado que aplica VarianceThreshold (< 0,01), filtro de correlação bivariada (|r| > 0,90) e Fator de Inflação da Variância iterativo (VIF = $1/(1 - R^2_j)$ <= 10), eliminando exatamente as 10 combinações lineares redundantes (40 → 30 colunas). (2) Cálculo Out-of-Fold (3-Fold Stratified OOF) da matriz TreeSHAP Φ_OOF nos 30 atributos candidatos, garantindo que cada atribuição seja extraída fora da amostra de treino da árvore; em seguida, ajusta-se regressão Logit de y_train sobre Φ_OOF, retendo apenas atributos com coeficiente $\beta > 0$ e p-valor < 0,05 (sem corte Top-K manual). (3) Avaliação do subconjunto selecionado tanto com o estimador padrão (ceteris paribus) quanto após otimização Bayesiana Optuna (20 tentativas TPE em CV de 5 folds).

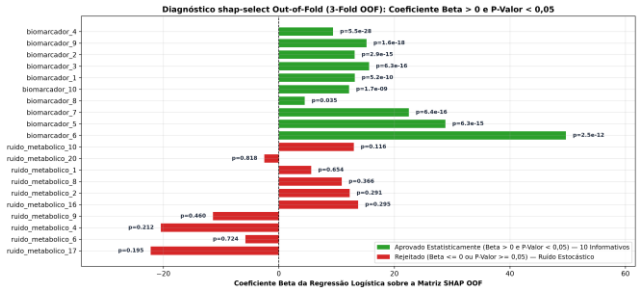


Fig. 2. Seleção inferencial shap-select Out-of-Fold: aprovação exata dos 10 atributos informativos (p < 0,05, verde) e rejeição do ruído (vermelho).

IV. EXPERIMENTOS, RESULTADOS E DISCUSSÃO

A. Benchmark Comparativo Multi-Famílias e Validação de H1 e H2

A Tabela I compara o pipeline proposto (com e sem Optuna) aos seis representantes clássicos (fixados em K = 10 atributos) e ao Baseline de 40 atributos, reportando métricas no holdout e média ± desvio-padrão em validação cruzada de 5 folds.

TABELA I: BENCHMARK MULTI-FAMÍLIAS (HOLDOUT E VALIDAÇÃO CRUZADA 5-FOLD)

Método / Abordagem	Inf.	Ruído	F1 Hold.	F1 CV (5f)	Acur.	AUC	Sel.(s)	Tr.(ms)
XAI (shap-select OOF + Optuna)	**10/10**	**0/20**	**0,8872**	**0,886±0,01**	**0,910**	**0,973**	**79,30**	**1076**
XAI (shap-select OOF Puro)	**10/10**	**0/20**	**0,8861**	**0,887±0,02**	**0,908**	**0,969**	**11,04**	**526**
Wrapper (RFE)	7/10	0/20	0,8759	0,853±0,01	0,898	0,958	4,55	575
Embedded (Lasso L1)	6/10	1/20	0,8689	0,862±0,01	0,892	0,963	0,05	583
Embedded (Tree MDI)	7/10	0/20	0,8558	0,841±0,01	0,880	0,949	0,01	613
Filter (ANOVA F)	7/10	0/20	0,8550	0,819±0,01	0,884	0,951	0,00	606
XAI (TreeSHAP)	7/10	0/20	0,8465	0,829±0,02	0,876	0,949	13,56	533
Filter (Mutual Info)	5/10	1/20	0,8365	0,823±0,02	0,864	0,938	0,41	546
Baseline (40 Atrib.)	10/10	20/20	0,8856	0,865±0,02	0,906	0,965	0,00	879

Os resultados da Tabela I confirmam integralmente H1: o pipeline proposto reduziu 75,0% da dimensionalidade (40 → 10 atributos) e, em vez de sofrer queda de desempenho, elevou o F1-Score de 0,8856 (Baseline) para 0,8861 na comparação ceteris paribus sem Optuna e para 0,8872 com Optuna (ganho de +0,0016 no holdout e 0,8864 na validação cruzada), comprovando a mitigação empírica do Fenômeno de Hughes.

Em relação a H2, a proposta foi o único método de todo o benchmark a recuperar 100% do ground truth informativo (10/10 informativos, 0/10 redundantes e 0/20 ruídos). Os demais métodos (RFE, ANOVA, Tree MDI e TreeSHAP direto) retiveram entre 6 e 7 atributos informativos porque selecionaram de 3 a 4 variáveis redundantes colineares. Quanto ao custo computacional, o treino do classificador final caiu 40,2% (878,8 ms para 525,7 ms); contudo, o tempo de seleção offline da proposta (11,04 s sem Optuna; 79,30 s com Optuna) foi superior ao RFE (4,55 s), rejeitando-se o subcritério de velocidade de seleção de H2.

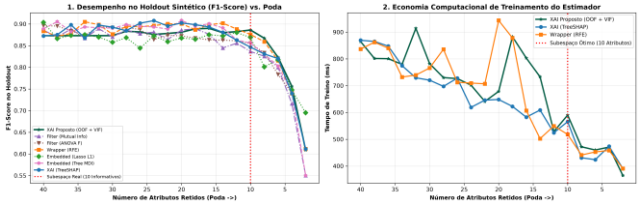


Fig. 3. Curvas de ablação progressiva (40 a 2 atributos): superioridade da trajetória OOF+VIF (verde escuro) no ponto ótimo K = 10.

B. Auditoria Local LIME: Observação Crítica e Coorte de Fronteira

Para testar H3 com robustez estatística, a auditoria LIME foi executada na observação mais incerta do holdout (#295, P = 50,0%) e na coorte das N = 20 observações mais próximas da fronteira P = 50% (Tabela II e Fig. 4). Na observação #295, a fidelidade local R^2 subiu de 0,3066 para 0,3851. Na coorte de fronteira (N = 20), o R^2 médio passou de 0,2478 para 0,2555, mantendo-se moderado devido à natureza altamente não-linear das árvores na zona de transição. Entretanto, o modelo baseline incluiu em média 3,80 variáveis não-informativas (redundantes ou ruído) entre as 10 principais regras locais do LIME, ao passo que o modelo reduzido reduziu essa contaminação local a 0,00.

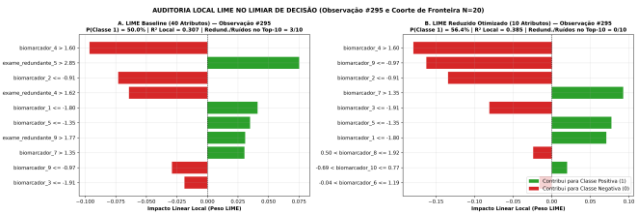


Fig. 4. Auditoria local LIME na observação limítrofe #295 (P = 50,0%): comparação de regras locais e fidelidade R^2.

TABELA II: AUDITORIA DE INTERPRETABILIDADE E COORTE DE FRONTEIRA LIME

Dimensão Auditada	Baseline (40)	XAI (10 Atrib.)	Leitura Metodológica
Recuperação Ground Truth	10 inf./10 red./20 ruídos	10/10 inf. | 0 red. | 0 ruídos	Redução de 75,0% sem corte Top-K forçado
LIME R^2 (Obs. #295, P=50%)	0,3066	0,3851	Ganho local na instância mais incerta
LIME R^2 Coorte (N=20)	0,248±0,11	0,255±0,10	Ajuste linear restrito pela não-linearidade RF
Redund./Ruído Top-10 LIME (N=20)	3,80 / 10 regras	0,00 / 10 regras	Eliminação total de regras não-informativas
Massa SHAP / Miller	100% (40 col.)	51,5% (10 col.)	Sem validação clínica ou teste cognitivo humano

V. CONCLUSÕES E LIMITAÇÕES

Respondendo à questão de pesquisa: o acoplamento de pré-filtragem multivariada (VIF <= 10) com seleção inferencial TreeSHAP Out-of-Fold (shap-select, p < 0,05) permitiu recuperar exatamente os 10 atributos informativos verdadeiros (10/10) e eliminar 100% dos atributos redundantes e de ruído sem depender de um número K arbitrário. A redução de 75% dos dados elevou o F1-Score no holdout (0,8856 → 0,8872) e na validação cruzada (0,8649 → 0,8864), confirmando H1 e a pureza de H2, embora com maior tempo de seleção offline que métodos filter e wrapper.

Como limitações metodológicas e epistemológicas, ressalta-se que: (i) os resultados decorrem de um benchmark sintético controlado, não configurando validação clínica; (ii) atribuições Shapley e LIME refletem associações preditivas do estimador e não causalidade física ou biológica; e (iii) a referência de Miller [8] (7 ± 2) é apenas teórica, inexistindo avaliação experimental com usuários humanos. Trabalhos futuros estenderão o protocolo OOF+VIF a bases reais multicêntricas de alta dimensionalidade.

REFERÊNCIAS

[1] C. Molnar, Interpretable Machine Learning: A Guide for Making Black Box Models Explainable, 2nd ed. Leanpub, 2022.

[2] R. Kohavi and G. H. John, "Wrappers for feature subset selection," Artificial Intelligence, vol. 97, no. 1-2, pp. 273-324, 1997.

[3] I. Guyon, J. Weston, S. Barnhill, and V. Vapnik, "Gene selection for cancer classification using support vector machines," Machine Learning, vol. 46, no. 1-3, pp. 389-422, 2002.

[4] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017, pp. 4765-4774.

[5] M. T. Ribeiro, S. Singh, and C. Guestrin, "'Why should I trust you?': Explaining the predictions of any classifier," in Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Min. (KDD), 2016, pp. 1135-1144.

[6] W. E. Marcílio and D. M. Eler, "From explainability to model improvement: A survey on XAI-based feature selection," IEEE Trans. Knowl. Data Eng., vol. 34, no. 11, pp. 5500-5515, 2020.

[7] D. Alvarez-Melis and T. S. Jaakkola, "Towards robust interpretability with self-explaining neural networks," in Advances in Neural Information Processing Systems (NeurIPS), vol. 31, 2018, pp. 7775-7784.

[8] G. A. Miller, "The magical number seven, plus or minus two: Some limits on our capacity for processing information," Psychological Review, vol. 63, no. 2, pp. 81-97, 1956.