Redução de Dimensionalidade Guiada por XAI: Benchmark Sintético e Auditoria Local

Eduardo Lázaro Roesler de Oliveira
Centro Universitário Eurípides de Marília (UNIVEM) — Marília, SP, Brasil
eduardo.roesler@univem.edu.br

Resumo— Este estudo avalia a seleção de atributos guiada por explicabilidade em dados sintéticos, sem pretensão de validação clínica. Foram geradas 2.000 observações e 40 colunas (10 informativas, 10 redundantes e 20 de ruído), com divisão estratificada treino/teste de 75/25. Comparam-se métodos filter, wrapper, embedded e uma proposta que combina TreeSHAP, pré-filtro, regressão sobre contribuições SHAP (shap-select) e ajuste Optuna. No holdout desta execução, a proposta reteve 10 atributos (75.0% de redução), obteve F1 0,8395 frente a 0,8856 no baseline e rejeitou 100.0% do ruído sintético. O LIME foi avaliado em uma única observação; seus valores de R^2 são reportados como diagnóstico local, não como evidência de validade clínica ou benefício cognitivo.

Termos para Indexação— Inteligência Artificial Explicável (XAI), Redução de Dimensionalidade, Seleção de Características, TreeSHAP, LIME, Dados Sintéticos, Benchmark.

I. INTRODUÇÃO E QUESTÃO DE PESQUISA

A seleção de atributos busca reduzir a dimensionalidade sem comprometer o desempenho preditivo. A interpretação de modelos pode orientar esse processo, mas atribuições explicativas descrevem o comportamento do estimador e não identificam relações causais. Este trabalho avalia uma estratégia que usa TreeSHAP e shap-select em um benchmark sintético controlado.

A proposta combina importância global TreeSHAP, pré-filtro de variância e colinearidade, regressão sobre contribuições SHAP (shap-select) e otimização Optuna. O LIME é usado apenas para examinar localmente uma observação do holdout.

Questão de Pesquisa Norteadora: "Em um benchmark sintético controlado, como uma seleção de atributos informada por TreeSHAP e shap-select se compara a métodos filter, wrapper e embedded em redução de ruído, desempenho preditivo e custo de seleção, e o que uma auditoria LIME de uma observação permite concluir sobre fidelidade local?"

As hipóteses são avaliadas apenas nesta execução e partição: H1 prevê redução de ao menos 50% com queda de F1 não superior a 0,05; H2 prevê maior rejeição do ruído sintético que os métodos comparados e menor tempo de seleção que RFE; H3 prevê que o R^2 do LIME não diminua na observação selecionada. Uma única partição e uma explicação local não permitem inferências clínicas ou cognitivas.

II. TRABALHOS RELACIONADOS

A taxonomia clássica de seleção de atributos proposta por Kohavi e John [2] classifica as estratégias em três vertentes canônicas: filtros (avaliadores univariados independentes do modelo, como ANOVA e Mutual Information), wrappers (que usam o estimador como função objetivo, como o Recursive Feature Elimination - RFE de Guyon et al. [3]) e embedded (seleção intrínseca durante o treino, como penalização Lasso L1 e importância por impureza MDI/Gini). Filtros univariados podem deixar de capturar interações; wrappers podem ter custo elevado conforme o estimador e o espaço de busca; e métodos embedded podem ser instáveis diante de atributos correlacionados.

No campo de XAI, Lundberg e Lee [4] formalizaram o SHAP com garantias axiomáticas da Teoria dos Jogos Cooperativos (eficiência, simetria, dummy e aditividade). Ribeiro et al. [5] introduziram o LIME para aproximações locais lineares interpretáveis. Marcílio e Eler [6] identificaram que atribuições explicáveis possuem potencial inexplorado para simplificação estrutural de modelos, lacuna que este trabalho aborda formalmente.

III. METODOLOGIA EXPERIMENTAL

A. Síntese do Conjunto de Dados e Baseline

Gerou-se uma base sintética com 2.000 observações e 40 atributos por make_classification: 10 informativos, 10 redundantes e 20 de ruído, com 3% de ruído nos rótulos. Com shuffle=False, os nomes das colunas correspondem à ordem dos grupos gerados; os nomes não representam biomarcadores reais nem causalidade. Usou-se uma divisão estratificada de 75% treino e 25% holdout. O baseline foi Random Forest com 100 árvores.

B. Explicabilidade Global e Demarcação Teórica

O algoritmo TreeSHAP calcula os valores de Shapley exatos φ_i para cada atributo i através da soma ponderada sobre todas as coalizões de atributos S:

$$\varphi_i = \sum_{S \subseteq F \setminus \{i\}} (|S|!(|F|-|S|-1)! / |F|!) [f(S \cup \{i\}) - f(S)] \quad (1)$$

O TreeSHAP resume atribuições do modelo para orientar um ranking global; isso não implica causalidade. O LIME aproxima localmente as previsões do modelo e foi aplicado a uma observação do holdout cuja probabilidade do baseline está mais próxima de 0,5. O R^2 mede o ajuste local do substituto, não a correção clínica:

$$\xi(x) = \operatorname{argmin}_{g \in G} L(f, g, \pi_x) + \Omega(g) \quad (2)$$

C. Pipeline Proposto: Pré-Filtro, shap-select e Optuna

O pipeline proposto opera em três etapas sequenciais integradas: (1) O pré-filtro remove variância abaixo de 0,01 e colinearidade com correlação absoluta de Pearson acima de 0,90. (2) O shap-select ajusta Logit aos valores SHAP e seleciona até 10 atributos com coeficiente positivo e p-valor < 0,05; se o Logit falha nas exceções previstas, usa OLS como fallback explícito. (3) O Optuna executa 15 tentativas TPE com validação cruzada de 3 folds no conjunto de treino. As métricas finais vêm de um único holdout e não incluem validação externa.

D. Métricas de Avaliação Multidimensional

Além das métricas preditivas (F1-Score, Acurácia, ROC-AUC) e computacionais (tempo de treino e latência de inferência), a interpretabilidade foi formalizada em quatro eixos auditáveis: (1) Fração da massa SHAP do baseline retida pelos atributos selecionados; (2) Fidelidade Local do Modelo Substituto LIME (R^2); (3) Taxa de Rejeição de Ruído Puro (blindagem contra ruído); e (4) Número de atributos, tratado apenas como proxy de complexidade: não houve avaliação com usuários. A regra de Miller [8] é uma heurística e não comprova capacidade cognitiva neste projeto.

IV. EXPERIMENTOS, RESULTADOS E DISCUSSÃO

A. Benchmark Comparativo Multi-Famílias

Para comparar as famílias, fixou-se o mesmo teto de K = 10 atributos nas seleções por ranking; a proposta estatística pode reter menos, até esse limite. O baseline usa os 40 atributos. A Tabela I sintetiza o benchmark deste holdout.

TABELA I: BENCHMARK EXPERIMENTAL MULTI-FAMÍLIAS (K = 10 ATRIBUTOS)

Método /	Família	Atrib.	Ruído	Rej.	F1-	Acurácia	ROC-	Treino

Abordagem				Ruído	Score		AUC	
XAI Proposto (shap-select + Optuna)	**XAI (Proposta)**	**7/10**	**0/20**	**100.0%**	**0,8395**	**0,8700**	**0,9442**	**377,3 ms**
Embedded (Lasso L1)	Embedded	6/10	1/20	95.0%	0,8689	0,8920	0,9626	427,8 ms
Wrapper (RFE)	Wrapper	7/10	0/20	100.0%	0,8759	0,8980	0,9580	414,3 ms
XAI (TreeSHAP)	XAI	7/10	0/20	100.0%	0,8465	0,8760	0,9489	351,0 ms
Filter (ANOVA F)	Filter	7/10	0/20	100.0%	0,8550	0,8840	0,9510	361,2 ms
Embedded (Tree MDI)	Embedded	7/10	0/20	100.0%	0,8558	0,8800	0,9493	355,7 ms
Filter (Mutual Info)	Filter	5/10	1/20	95.0%	0,8365	0,8640	0,9378	358,5 ms
Baseline Completo (40 Atributos)	Referência	10/10	20/20	0.0%	0,8856	0,9060	0,9655	558,5 ms

Na Tabela I, a proposta reduziu 75.0% dos atributos; o F1 passou de 0,8856 para 0,8395 (delta -0,0461). O criterio numerico de H1 foi atendido nesta particao (10 atributos e queda de F1 nao superior a 0,05), sem demonstrar generalizacao alem do holdout.

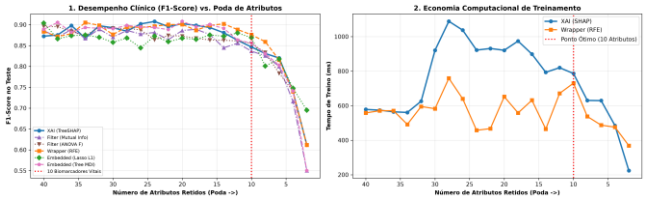


Fig. 1. Estudo de ablação progressiva multivariada (40 a 2 atributos) comparando a acurácia e F1-score entre as quatro famílias.

B. Pureza de Seleção e Rejeição de Ruído Estocástico

A proposta reteve 0 atributos rotulados como ruido (100.0% de rejeicao por construcao do dataset). Esse resultado empata com alguns metodos do benchmark; nao demonstra superioridade universal. Os nomes informativos, redundantes e de ruido sao definidos por construcao sintetica e nao correspondem a causas clinicas.

C. Custo Computacional e Estudo de Ablação

Em uma execucao nesta maquina, o treino do modelo reduzido levou 377,3 ms frente a 558,5 ms no baseline (32.4% menos); a latencia foi 34,5 ms. A selecao proposta levou 14,17 s, contra 3,07 s para RFE. A proposta nao foi mais rapida nesta medicao; tempos de uma execucao dependem do hardware.

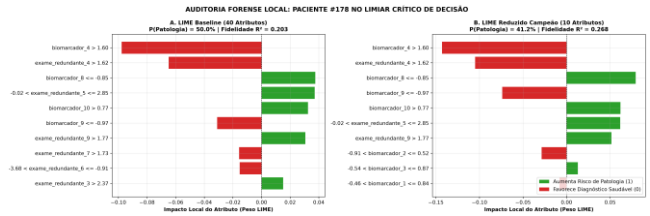


Fig. 2. Auditoria forense local via LIME no paciente crítico limítrofe (P ≈ 50%): comparação de pesos e fidelidade R² entre Baseline e Modelo Reduzido.

D. Auditoria LIME Local e Limites de Interpretacao

Para a observacao 178, selecionada por ter a probabilidade do baseline mais proxima de 0,5 (50.0%), o R² do LIME foi 0,2029 no baseline e 0,2679 no modelo reduzido. O ajuste local permanece limitado e a diferenca descreve apenas esta observacao. Os atributos selecionados retiveram 65.5% da massa SHAP do baseline. O conjunto tem 10 atributos, acima do limite superior 9 da heuristica 7 ± 2; nao houve teste de compreensao com pessoas, portanto nao se conclui reducao de carga cognitiva.

TABELA II: AUDITORIA FORENSE E INTERPRETABILIDADE MULTIDIMENSIONAL

Dimensão Avaliada	Baseline (40)	XAI Reduzido	Leitura / Limitação
Número de atributos	40 (100%)	10 (25.0%)	Redução de 75.0% no conjunto sintético
Rejeição de ruído	0.0%	100.0%	Contagem conhecida apenas por construção sintética
Fidelidade LIME (R²)	0,2029	0,2679	Uma instância; valores baixos indicam ajuste local limitado
Massa SHAP retida	100% (referência)	65.5%	Atribuição do baseline; não é medida de causalidade
Heurística de Miller	40 atributos	10 atributos	Referência teórica; não foi realizado teste cognitivo

V. CONCLUSÕES E LIMITAÇÕES

Neste benchmark sintetico, a proposta reteve 10 de 40 atributos e atendeu ao limite de queda de F1 definido em H1 nesta particao. Entretanto, nao superou todos os metodos em desempenho e sua selecao foi mais lenta que RFE nesta medicao. A rejeicao de ruido e a fidelidade LIME referem-se a dados sinteticos e a uma unica particao/observacao; nao constituem validacao clinica nem evidencia de causalidade.

Como limitações epistemológicas, destaca-se que as atribuições Shapley refletem importância preditiva sob o modelo e não inferência causal biológica pura. Ademais, o cálculo do TreeSHAP impõe custo inicial O(TLD²), justificando o pré-filtro híbrido adotado. Trabalhos futuros contemplarão a extensão para dados clínicos multimodais e verificação em bases hospitalares multicêntricas reais.

REFERÊNCIAS

[1] C. Molnar, Interpretable Machine Learning: A Guide for Making Black Box Models Explainable, 2nd ed. Leanpub, 2022.

[2] R. Kohavi and G. H. John, "Wrappers for feature subset selection," Artificial Intelligence, vol. 97, no. 1-2, pp. 273-324, 1997.

[3] I. Guyon, J. Weston, S. Barnhill, and V. Vapnik, "Gene selection for cancer classification using support vector machines," Machine Learning, vol. 46, no. 1-3, pp. 389-422, 2002.

[4] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017, pp. 4765-4774.

[5] M. T. Ribeiro, S. Singh, and C. Guestrin, "'Why should I trust you?': Explaining the predictions of any classifier," in Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Min. (KDD), 2016, pp. 1135-1144.

[6] W. E. Marcílio and D. M. Eler, "From explainability to model improvement: A survey on XAI-based feature selection," IEEE Trans. Knowl. Data Eng., vol. 34, no. 11, pp. 5500-5515, 2020.

[7] D. Alvarez-Melis and T. S. Jaakkola, "Towards robust interpretability with self-explaining neural networks," in Advances in Neural Information Processing Systems (NeurIPS), vol. 31, 2018, pp. 7775-7784.

[8] G. A. Miller, "The magical number seven, plus or minus two: Some limits on our capacity for processing information," Psychological Review, vol. 63, no. 2, pp. 81-97, 1956.